

TabUF Episode API 调用说明

给 Agent 与程序的调用合同

仓库 1587causalai/tabuf-episode-api

2026 年 8 月 15 日 v0

表怎么生成见 docs/data-generation.pdf; 本文件只讲怎么调用。

机器可读: /docs、/redoc、/openapi.json

1 给谁看 / 三十秒合同

给要正确调用本服务的 Agent 或程序。不是生成手册。

POST /v0/episodes 返回 n_{episodes} 条不同 episode (默认 8), 按 batch_size (默认 8) 打包; 组内同形状, 下一组重抽 d, k 。每条含 values、missing_mask、query_mask。没有额外的 y 。只拿 table 训练。

HTTP/1.1, JSON, UTF-8。无鉴权。可复现性靠 seed。掩码是 JSON boolean。values 不因 mask 挖空。单次最多 32 条。

2 基址与端点

本机基址: <http://127.0.0.1:8787>。公网隧道会变, 见附录 A。

方法	路径	作用
GET	/health	存活。{"ok": true, "version": "v0"}
GET	/v0/sources	来源目录 (canonical + 别名)
POST	/v0/episodes	抽 episode
GET	/docs /redoc /openapi.json	schema

/v0 是信封版本。换共享张量合同才升 /v1。

3 POST 请求字段

路径 POST /v0/episodes。未写的字段用默认。其它来源会静默忽略 discoscmm-only 字段。

字段	默认	范围	谁认	含义
<code>n_units</code>	1000	[8, 4096]	共享（行数）	仅 discoscsm 把行当 unit；其它 = n_{samples}
<code>n_features</code>	null	[2, 1000]	共享	列数；null 则每个 batch 抽一次；其它来源回退 20
<code>seed</code>	0	—	共享	第 e 集用 $\text{seed} + e$
<code>n_episodes</code>	8	[1, 32]	共享	不同生成世界的条数；可大于 <code>batch_size</code>
<code>batch_size</code>	8	[1, 32]	共享	一组同形状的条数；下一组重抽 d, k
<code>source</code>	discoscsm	—	共享	生成器 canonical 名或别名
<code>source_name</code>	null	—	别名	别名用的子名。canonical 已自带则忽略
<code>missing_frac</code>	画像	[0, 0.95)	共享	null 则用该 source 画像
<code>query_frac</code>	画像	(0, 1)	共享	<code>label_column</code> 时无意义
<code>query_mode</code>	画像	—	共享	<code>cells / label_column / observed_cells</code>
<code>return_mechanism</code>	false	—	共享	是否附带生成说明块
<code>sigma</code>	0.3	[0, 10]	discoscsm+scm	噪声标准差
<code>debug</code>	false	—	discoscsm-only	额外潜分数；其它来源忽略
<code>unit_dim</code>	null	[2, 1024]	discoscsm-only	k ；null 则每个 batch 抽一次
<code>type_weights</code>	70:5:10:5:5	≥ 0 , 和 > 0	discoscsm-only	列类型权重（不必归一化）
<code>independent_frac</code>	0.05	[0, 1]	discoscsm-only	列与 u 断开、改抽边缘的概率
<code>max_parents</code>	null	[1, 512]	discoscsm-only	null: 典型上限 6 + 少量 hub；整数: 全体硬上限
<code>dag_edge_p</code>	0.3	[0, 1]	discoscsm-only	遗留；仍写入 <code>response_law</code> ，新 DAG 不用 Bernoulli(p)

`type_weights` 五键: numeric/ordinal/binary/categorical/high_cardinality。

4 响应形状

成功时 HTTP 200。response_model_exclude_none=true: 值为 null 的可选键不出现。

```
{
  "n_episodes": 8,
  "batch_size": 8,
  "n_batches": 1,
  "n_units": 16,
  "n_features": 8,
  "unit_dim": 4,
  "shape": [16, 8],
  "batches": [{ "batch_index": 0, "shape": [16, 8], "episodes": ["..."] }],
  "episodes": [{
    "seed": 0,
    "table": {
      "n_units": 16, "n_rows": 16, "n_features": 8, "unit_dim": 4,
      "source": "discoscsm",
      "values": [...],
      "missing_mask": [[false, ...], ...],
      "query_mask": [[true, ...], ...],
      "column_types": ["numeric", ...],
      "n_classes": [null, ...],
      "query_mode": "cells",
```

```

    "shapes": {
      "values": [16, 8],
      "missing_mask": [16, 8],
      "query_mask": [16, 8],
      "n_missing": 6, "n_query": 19, "n_query_and_missing": 1
    }
  }
}
}]
}

```

column_types: numeric / ordinal / binary / categorical / high_cardinality。没有 y_query / y_input / context_mask。return_mechanism=true 时可能多出第 6 节的键。

5 来源目录

以 canonical 名为准。GET /v0/sources 返回同样的画像。未知名 → 422,detail 列出 canonical。

canonical	别名	行含义	query	missing	HTTP
discoscm	—	unit	cells 0.15	0.05	200
scm	—	iid_sample	label_column	0	200
sklearn_make_classification	synth*	iid_sample	label_column	0	200
sklearn_make_regression	synth*	iid_sample	label_column	0	200
sklearn_friedman1	synth*	iid_sample	label_column	0	200
sklearn_low_rank	synth*	iid_sample	cells 0.15	0.05	200
sklearn_iris	real [†]	entity_row	label_column	0	200
sklearn_wine	real [†]	entity_row	label_column	0	200
sklearn_breast_cancer	real [†]	entity_row	label_column	0	200
sklearn_diabetes	real [†]	entity_row	label_column	0	200
openml	—	entity_row	label_column	0	501
recsys	—	user	observed_cells 0.15	未观测	501

* 别名 sklearn_synthetic。† 别名 sklearn_real。

别名用法:

- sklearn_synthetic:source_name 为 make_classification、make_regression、make_friedman1、make_low_rank_matrix。省略则随机抽一个，并套用该 canonical 画像。
- sklearn_real: source_name 取 iris / wine / breast_cancer / diabetes；省略则随机。

label_column: query 为最后一整列 (标签/y)。sklearn_low_rank 无标签列。recsys 未观测格即 missing; query 是已观测评分的子集。

6 return_mechanism: 哪些键出现

return_mechanism=true (discoscm 上 debug=true 同样附带) 时, 按 source 出现不同键。不要解释这些块; 不要喂进网络。

source	会出现	不会出现
discoscm	population(mixture+assignment+representation) + response_law	mechanism
scm	mechanism: framework=ANM-SCM, edges, node_fn, target_col	population、response_law
sklearn_*	mechanism: maker 或 dataset	population、response_law
openml / recsys	—	整条请求 501, 无 episode

population.mixture: $n_components=M$, M 在 $1 \dots \lfloor \sqrt{n} \rfloor$ 上 $P(M=m) \propto 1/m$; 每个分量 family 为 gaussian 或 cauchy。assignment[i] 是 unit i 的分量下标。含义见生成手册附录 A.2。

7 可复制 curl

把基址换成当前服务地址。默认空 body = discoscm。

```
curl -s http://127.0.0.1:8787/health

curl -s http://127.0.0.1:8787/v0/sources

curl -s -X POST http://127.0.0.1:8787/v0/episodes \
  -H 'Content-Type: application/json' -d '{}'
```

```
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
  -H 'Content-Type: application/json' \
  -d '{"source": "scm", "n_units": 32, "n_features": 8, "seed": 1, "return_mechanism": true}'
```

```
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
  -H 'Content-Type: application/json' \
  -d '{"source": "sklearn_iris", "n_units": 30, "n_features": 5, "seed": 0}'
```

8 错误码

码	何时
200	成功。body 为上一节的 JSON。
422	字段越界 (n_units/n_features/unit_dim/sigma 等 le=/ge=); 未知 source (detail 列出 canonical 名); 非法 source_name; type_weights 之和 ≤ 0 。
501	openml 或 recsys: 已占位, 缓存未接。
404	路径不存在。
405	方法不对 (例如 GET /v0/episodes)。

9 不要做

- 不要把 population / response_law / mechanism 喂进网络。只训 table。
- 不要期望 y_query / y_input / context_mask。真值在 values 的 query 格。

- 不要把 `n_units` 一律当成 `unit`。只有 `source=discoscm` 把行解释成 `unit`；其它来源它是行数 / n_{samples} 。

A 公网隧道

会变。当前: <https://spotlight-predicted-heaven-clips.trycloudflare.com>。优先用本机 <http://127.0.0.1:8787>。