

TabUF Episode API 接口文档

第零版观测数据服务

仓库 1587causalai/tabuf-episode-api

2026 年 8 月 14 日

目录

1	这份文档管什么	2
2	服务地址	2
3	约定	2
4	端点一览	3
5	GET /health	3
6	POST /v0/episodes	3
6.1	请求体	3
6.2	响应 200	4
6.3	错误	5
7	调用例子	5
8	和生成文档的分工	5

1 这份文档管什么

生成语义（总体、unit-specific 响应律、C/Q 出题）写在 docs/data-generation.pdf。这份文档只写运输层：地址、方法、字段、状态码、例子。字段名可以改，改的时候先改生成文档，再改这里，再改代码。

交互式文档由 FastAPI 自动生成，和本文同步：

- Swagger UI: /docs
- ReDoc: /redoc
- OpenAPI JSON: /openapi.json

2 服务地址

当前部署在文献调研这台机器上，本机回环 + 一条临时公网隧道。

角色	URL
本机	http://127.0.0.1:8787
公网隧道（会变）	https://spotlight-predicted-heaven-clips.trycloudflare.com

说明

隧道是 Cloudflare Quick Tunnel，没有 SLA，URL 在进程重启后会换。稳定入口始终是本机 127.0.0.1:8787。无鉴权、无 HTTPS 终止以外的证书、无速率配额（单次最多 32 episode，格子上限见下表）。

3 约定

- 协议：HTTP/1.1, JSON, UTF-8。
- Content-Type: application/json。
- 无认证头。
- 时间：无时钟字段。可复现性靠 seed。
- 浮点：IEEE-754 JSON number。查询格在 y_input 里是 JSON null，不是字符串 "NaN"。
- 掩码：JSON boolean。
- 拉直顺序：行优先（C-order）。y_query[t] 对应 query_mask 拉直后第 t 个 true。

4 端点一览

方法	路径	作用	鉴权
GET	/health	存活	无
GET	/docs	Swagger UI	无
GET	/redoc	ReDoc	无
GET	/openapi.json	机器可读 schema	无
POST	/v0/episodes	抽取观测 episode	无

URL 里的 /v0 是生成语义版本，不是 HTTP 框架版本。换响应律或换张量合同，才升 /v1。

5 GET /health

探活。生成器能 import、进程在听端口，就返回 200。

响应 200

```
{"ok": true, "version": "v0"}
```

字段	类型	含义
ok	bool	恒为 true；能返回就说明活着
version	string	当前生成语义版本，现为 v0

6 POST /v0/episodes

抽一批观测 episode。每集独立：先抽总体 $\{\mathbf{u}_i\}$ ，再填 $Y_{ij} = \langle \mathbf{u}_i, \mathbf{w}_j \rangle + e_{ij}$ ，再切 C/Q 。

6.1 请求体

全部字段可选。缺省等于下表默认值。非法值返回 422。

字段	类型	默认	范围	含义
n_units	int	64	[8, 512]	本集 unit 数 n
n_features	int	8	[2, 64]	列数 d
unit_dim	int	4	[1, 32]	个体潜维 k
query_frac	float	0.15	(0, 1)	Q 占总格子比例
sigma	float	0.3	[0, 10]	观测噪声标准差
seed	int/null	0	—	基种子；第 e 集用 $\text{seed} + e$
n_episodes	int	1	[1, 32]	一次返回多少集（硬顶 32）
debug	bool	false	—	是否附带 U, W, Y_{full}

seed=null 时服务端随机抽一个基种子，仍然写入每集的 seed 字段，所以返回值可复现、请求不必可复现。

最小请求：空对象 $\{\}$ ，等价于 64×8 、 $k = 4$ 、 $q = 0.15$ 、1 集。

6.2 响应 200

```
{
  "episodes": [
    {
      "context_mask": [[true, false], ...],
      "query_mask":  [[false, true], ...],
      "y_input":      [[0.12, null], ...],
      "y_query":      [0.87, ...],
      "shapes": {
        "n_units": 16, "n_features": 4, "unit_dim": 4,
        "n_query": 10, "n_context": 54,
        "y_input": [16, 4],
        "context_mask": [16, 4],
        "query_mask": [16, 4],
        "y_query": [10]
      },
      "seed": 0
    }
  ]
}
```

字段	形状	含义
context_mask	$n \times d$ bool	M^C ; true $\Leftrightarrow$ 该格 $\in C$
query_mask	$n \times d$ bool	M^Q ; true $\Leftrightarrow$ 该格 $\in Q$
y_input	$n \times d$ float/null	C 上为 Y_{ij} , Q 上为 null
y_query	n_Q float	Q 上真值, 行优先拉直
shapes	对象	以上张量形状, 避免客户端猜
seed	int	本集实际使用的种子
U	$n \times k$	仅 debug=true
W	$d \times k$	仅 debug=true
Y_full	$n \times d$	仅 debug=true

不变量 (第零版):

$$\begin{aligned}
C \cap Q &= \emptyset, \\
C \cup Q &= \{1, \dots, n\} \times \{1, \dots, d\}, \\
n_Q &= \text{clip}(\text{round}(q \cdot nd), 1, nd - 1).
\end{aligned}$$

默认 payload 不含 U, W, Y_{full} 。debug=true 时才出现这三个键; false 时键直接省略, 不是 null。

训练合同

训练 DataLoader 禁止设 debug=true, 禁止把 U 喂进网络。 u_i 是个体真名。漏出去, 预训练就是漏题。

6.3 错误

状态码	何时	体
200	生成成功	见上
422	字段越界、类型不对、缺 JSON	FastAPI 校验错误列表
405	对 /v0/episodes 用了 GET 等	—
404	路径不存在	—

第零版没有业务错误码。格子太大被 `le=` 拦在 422，而不是生成到一半再 500。

7 调用例子

探活：

```
curl -s http://127.0.0.1:8787/health
```

最小生成：

```
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
-H 'Content-Type: application/json' \
-d '{}'
```

指定格子（推荐写进脚本的默认）：

```
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
-H 'Content-Type: application/json' \
-d '{
  "n_units": 16,
  "n_features": 4,
  "unit_dim": 4,
  "query_frac": 0.15,
  "sigma": 0.3,
  "seed": 0,
  "n_episodes": 2,
  "debug": false
}'
```

公网隧道把主机换成当前隧道 URL 即可，路径不变。

8 和生成文档的分工

问题	去哪看
为什么先抽总体	docs/data-generation.pdf
$Y_{ij} = \langle u_i, w_j \rangle + e_{ij}$	同上
C/Q 为什么是格子级	同上
这个字段叫什么、范围多少	本文
现在服务在哪	本文第 2 节

接口改了，先改本文表格，再改 `app.py` 的 Pydantic 约束，最后才 bump 例子。