

TabUF Episode API 接口文档

第零版观测数据服务

仓库 1587causalai/tabuf-episode-api

2026 年 8 月 14 日

目录

1	这份文档管什么	2
2	服务地址	2
3	约定	2
4	端点一览	3
5	GET /health	3
6	POST /v0/episodes	3
6.1	请求体	4
6.2	响应 200	4
6.3	打开机制时: 总体 + unit-specific law	5
6.4	数据来源 <code>source</code>	5
6.5	错误	6
7	调用例子	6
8	和生成文档的分工	6

1 这份文档管什么

生成语义（总体、unit-specific 响应律、C/Q 出题）写在 docs/data-generation.pdf。这份文档只写运输层：地址、方法、字段、状态码、例子。字段名可以改，改的时候先改生成文档，再改这里，再改代码。

交互式文档由 FastAPI 自动生成，和本文同步：

- Swagger UI: /docs
- ReDoc: /redoc
- OpenAPI JSON: /openapi.json

2 服务地址

当前部署在文献调研这台机器上，本机回环 + 一条临时公网隧道。

角色	URL
本机	http://127.0.0.1:8787
公网隧道（会变）	https://spotlight-predicted-heaven-clips.trycloudflare.com

说明

隧道是 Cloudflare Quick Tunnel，没有 SLA，URL 在进程重启后会换。稳定入口始终是本机 127.0.0.1:8787。无鉴权、无 HTTPS 终止以外的证书、无速率配额（单次最多 32 episode，格子上限见下表）。

3 约定

- 协议：HTTP/1.1, JSON, UTF-8。
- Content-Type: application/json。
- 无认证头。
- 时间：无时钟字段。可复现性靠 seed。
- 浮点：IEEE-754 JSON number。查询格在 y_input 里是 JSON null，不是字符串 "NaN"。
- 掩码：JSON boolean。
- 拉直顺序：行优先（C-order）。y_query[t] 对应 query_mask 拉直后第 t 个 true。

4 端点一览

方法	路径	作用	鉴权
GET	/health	存活	无
GET	/docs	Swagger UI	无
GET	/redoc	ReDoc	无
GET	/openapi.json	机器可读 schema	无
POST	/v0/episodes	抽取观测 episode	无

URL 里的 /v0 是生成语义版本，不是 HTTP 框架版本。换响应律或换张量合同，才升 /v1。

5 GET /health

探活。生成器能 import、进程在听端口，就返回 200。

响应 200

```
{"ok": true, "version": "v0"}
```

字段	类型	含义
ok	bool	恒为 true；能返回就说明活着
version	string	当前生成语义版本，现为 v0

6 POST /v0/episodes

一次返回 n_{ep} 条 episode，**每条各自抽一个总体**。表是完整的。missing 与 query 独立抽取，**允许重合**。

6.1 请求体

字段	类型	默认	范围	含义
n_units	int	64	[8, 512]	本集总体切片大小
n_features	int	8	[2, 64]	列数 d
unit_dim	int	4	[1, 32]	个体表征维 k
query_frac	float	0.15	(0, 1)	要预测的格子占全表比例
missing_frac	float	0.05	[0, 0.95)	世界缺失占全表比例
sigma	float	0.3	[0, 10]	潜变量噪声标准差
seed	int/null	0	—	第 e 集用 $\text{seed} + e$
n_episodes	int	1	[1, 32]	条数；各抽各的总体
type_weights	对象	见下	≥ 0	列类型抽样权重，不必归一化
independent_frac	float	0.05	[0, 1]	每列与其它特征独立的概率
source	string	discoscm	—	见下方来源表
source_name	string/null	null	—	子名称，如 iris、 make_classification
return_mechanism	bool	false	—	是否带总体和响应律
debug	bool	false	—	额外潜分数 S

两套 mask 独立按全表比例抽样，因此 $M \cap Q$ 一般非空，并集也不一定是 20%。 $Q \cap M$ 是缺失填补， $Q \setminus M$ 是普通预测。没有单独的 y 标签：真值就在完整的 values 里。网络可见的上下文是 $\neg M \wedge \neg Q$ ，不必再单开字段。

6.2 响应 200

```
{
  "n_episodes": 2,
  "episodes": [
    {
      "seed": 0,
      "table": {
        "n_units": 16,
        "n_features": 8,
        "values": [[0.12, 3, 17, ...], ...],
        "missing_mask": [[false, true, ...], ...],
        "query_mask": [[true, true, ...], ...],
        "column_types": ["numeric", "ordinal", "categorical", "high_cardinality",
        ...],
        "n_classes": [null, 5, 12, 80, ...],
        "shapes": {"n_missing": 6, "n_query": 19, "n_query_and_missing": 1}
      }
    }
  ]
}
```

values 从不因 mask 挖空。数值列是 float，离散列是 $\{0, \dots, K_j - 1\}$ 的 int。

列类型权重由请求体 type_weights 给出，默认 70:5:10:5:5（数值 / 有序 / 二值 / 多值 / 超多值），按权重归一化后多项抽样。independent_frac 默认 0.05。生成：数值 $Y =$

$\text{scale}\langle u, w \rangle + \text{shift} + e$; 有序为 ordered probit; 多值与超多值为 unit-specific multinomial logit (Gumbel 噪声), 超多值类嵌入尺度更散、频率更偏。

训练合同

训练只吃 `table`。真值用 `values` 在 `query_mask` 处取值。不要把 `population.representations` 喂进网络。

6.3 打开机制时：总体 + unit-specific law

`return_mechanism=true` 时, 每条 episode 多两块。它们描述表是怎么来的, 不是给网络的输入。

```
"population": {
  "id": "pop-0",
  "n_units": 16,
  "unit_dim": 4,
  "prior": "N(0, I)",
  "representations": [[...], ...]  // 行 i 是 unit u_i 的表征
},
"response_law": {
  "form": "unit_specific_factor",
  "assignment": "Y[i,j] = <U[i], W[j]> + E[i,j]",
  "W": {"values": ..., "column_normalize": true},
  "noise": {"kind": "factual", "sigma": 0.3, "values": ...}
}
```

同一条 law 作用在每个人身上; unit-specific 是因为代入了这个人的 u_i 。第零版 E 只抽一次, 不重抽反事实噪声。用表征、 W 、 E 可还原满表。`debug` 才会再给潜分数 S 。

训练合同

`population.representations` 就是个体真名。检查生成器用, 不要进训练。

6.4 数据来源 source

默认 `discoscm` 仍是 unit-specific law。其它来源编进同一套完整表 + missing/query。

source	状态	含义
<code>discoscm</code>	默认	先抽总体, 再 unit-specific $g_j(u_i)$
<code>sklearn_synthetic</code>	可用	<code>make_classification/regression/friedman1/low_rank</code>
<code>sklearn_real</code>	可用	iris / wine / breast_cancer / diabetes
<code>scm</code>	可用	论文风格 ANM: 特征上的随机 DAG, 行 i.i.d.
<code>openml</code>	占位	OpenML 分类/回归, 尚未接缓存
<code>recsys</code>	占位	真实推荐表 (MovieLens 等), 尚未接缓存

`scm` / `sklearn` 的行不是 DiscoSCM unit。机制打开时会写明这一点。

6.5 错误

状态码	何时	体
200	生成成功	见上
422	字段越界、类型不对、缺 JSON	FastAPI 校验错误列表
405	对 /v0/episodes 用了 GET 等	—
404	路径不存在	—

第零版没有业务错误码。格子太大被 `le=` 拦在 422，而不是生成到一半再 500。

7 调用例子

探活：

```
curl -s http://127.0.0.1:8787/health
```

最小生成：

```
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
-H 'Content-Type: application/json' \
-d '{}'
```

指定格子（推荐写进脚本的默认）：

```
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
-H 'Content-Type: application/json' \
-d '{
    "n_units": 16,
    "n_features": 4,
    "unit_dim": 4,
    "query_frac": 0.15,
    "missing_frac": 0.05,
    "sigma": 0.3,
    "seed": 0,
    "n_episodes": 2,
    "return_mechanism": false,
    "debug": false
}'
```

公网隧道把主机换成当前隧道 URL 即可，路径不变。

8 和生成文档的分工

问题	去哪看
为什么先抽总体	docs/data-generation.pdf
$Y_{ij} = \langle u_i, w_j \rangle + e_{ij}$	同上
C/Q 为什么是格子级	同上
这个字段叫什么、范围多少	本文
现在服务在哪	本文第 2 节

接口改了，先改本文表格，再改 `app.py` 的 Pydantic 约束，最后才 bump 例子。