

TabUF Episode API 接口文档

第零版观测数据服务

仓库 1587causalai/tabuf-episode-api

2026 年 8 月 14 日

目录

1 这份文档管什么	2
2 信封	2
3 字段分家	2
4 来源是通道，不是方言	2
5 端点	3
6 和生成文档的分工	3
A 服务地址与约定	4
B 请求字段表	4
C GET /v0/sources 画像	4
D 各来源默认 mask	5
E JSON 信封与 curl	5
F 机制字段对照	6
G 错误码	6

1 这份文档管什么

运输层。生成数学不在此处。

POST /v0/episodes 返回 n 条 episode。共享的只有信封：完整表 values，外加 missing_mask / query_mask。没有单独的 y 。真值就在 values 里。

各 source 是不同通道，不是 DiscoSCM 的变体。DiscoSCM 公式见 docs/data-generation.pdf 附录 A。其它通道的语义在那份文档的附录 B-F；本文只写字段归属和怎么调。默认数字、JSON 样例、字段表，全部在本文附录，不进正文。

机器可读对照：/docs、/redoc、/openapi.json、GET /v0/sources。

2 信封

一次请求要 n_{ep} 张表，source 选生成器，默认 discoscsm。

每条 episode 有一张完整表。Compiler 只盖两张独立的 mask，不改格子上的数。 n_{units} 在线上是行数旋钮：只有 discoscsm 把行当成 unit；scm / sklearn 里它就是样本数。

训练只吃 table。不要把 population、response_law 或 mechanism 喂进网络。

3 字段分家

请求里有两类字段。

共享（所有来源都认）：行数 n_{units} 、列数 n_{features} 、seed、 n_{episodes} 、source、缺失/query 比例与 query_mode、return_mechanism。别名还认 source_name。

只对 discoscsm 生效：unit_dim、type_weights、independent_frac、debug。其它来源静默忽略。sigma 只对 discoscsm 与 scm 有噪声含义。

return_mechanism=true 时，字段名看来源：discoscsm 给 population+response_law；scm / sklearn 给 mechanism，不会带 population / response_law。不要在 scm 上读 DiscoSCM 的块。

完整范围表见附录 B。

4 来源是通道，不是方言

canonical 名：discoscsm, scm, sklearn_make_classification, sklearn_make_regression, sklearn_friedman1, sklearn_low_rank, sklearn_iris, sklearn_wine, sklearn_breast_cancer, sklearn_diabetes, openml, recsys。

别名 sklearn_synthetic / sklearn_real 仍可用。目录、行含义、默认 mask：GET /v0/sources，表在附录 D。

一句话归属（细节不在正文）：

- discoscsm：行是 unit，有 u_i 。机制字段是 population / response_law。
- scm：特征 DAG 上的 i.i.d. 行，无 unit token，最后一列是预测目标。机制是 DAG。
- sklearn 合成 / 真实表：i.i.d. 或实体行。多数最后一列是标签；low_rank 没有标签。
- openml / recsys：占位，501。

5 端点

方法	路径	作用
GET	/health	存活
GET	/v0/sources	来源目录
POST	/v0/episodes	抽 episode
GET	/docs /redoc /openapi.json	schema

/v0 是信封版本。换共享张量合同才升 /v1。未知 source 返回 422 并列 canonical 名；openml / recsys 返回 501。地址、curl、错误码在附录。

6 和生成文档的分工

问题	去哪看
喂给网络什么、通道为什么分开	data-generation.pdf 正文
DiscoSCM / SCM / sklearn 的生成细节	那份文档的附录
这个字段叫什么、范围多少、怎么 curl	本文附录
现在服务在哪	本文附录 A

A 服务地址与约定

本机 <http://127.0.0.1:8787>。公网隧道(会变)<https://spotlight-predicted-heaven-clips.trycloudflare.com>。无鉴权。单次最多 32 episode。

HTTP/1.1, JSON, UTF-8。可复现性靠 seed。掩码是 JSON boolean。values 不因 mask 挖空。没有 y_query / y_input / context_mask。

B 请求字段表

字段	默认	范围	作用域	含义
n_units	64	[8, 512]	共享 (行数)	discoscm=unit 数; 其它 $=n_{\text{samples}}$
n_features	8	[2, 64]	共享	列数
seed	0	—	共享	第 e 集用 $\text{seed} + e$
n_episodes	1	[1, 32]	共享	条数
source	discoscm	—	共享	生成器
source_name	null	—	别名	sklearn 别名 / 占位的子名
missing_frac	画像	[0, 0.95)	共享	null 则用画像
query_frac	画像	(0, 1)	共享	label_column 时无意义
query_mode	画像	—	共享	cells / label_column / observed_cells
return_mechanism	false	—	共享	是否附带生成说明
sigma	0.3	[0, 10]	discoscm+scm	噪声标准差
debug	false	—	discoscm-only	额外潜分数
unit_dim	4	[1, 32]	discoscm-only	个体表征维
type_weights	见生成文档	≥ 0	discoscm-only	列类型权重
independent_frac	0.05	[0, 1]	discoscm-only	列边缘独立概率

C GET /v0/sources 画像

每条来源 (canonical + 别名) 返回: status (ready / placeholder), family, row_meaning (unit / iid_sample / entity_row / user), query_mode, missing_frac, query_frac, uses_unit_token, request_fields_used / request_fields_ignored, 一句 note (除 discoscm 外不用 DiscoSCM 黑话)。

D 各来源默认 mask

source	行含义	query	missing	备注
discoscm	unit	cells 0.15	0.05	唯一有 unit token
scm	iid_sample	label_column	0	最后一列是 y
sklearn_make_classification	iid_sample	label_column	0	最后一列二值 y
sklearn_make_regression	iid_sample	label_column	0	连续 y
sklearn_friedman1	iid_sample	label_column	0	连续 y
sklearn_low_rank	iid_sample	cells 0.15	0.05	无标签, 矩阵补全
sklearn_iris 等四张真实表	entity_row	label_column	0	最后一列标签/靶
openml	entity_row	label_column	0	501
recsys	user	observed_cells 0.15	未观测 =missing	501

sklearn 真实表: iris / wine / breast_cancer / diabetes。别名 sklearn_synthetic、sklearn_real 套用被抽中的 canonical 画像。

E JSON 信封与 curl

```
{
  "n_episodes": 1,
  "episodes": [{
    "seed": 0,
    "table": {
      "n_units": 16, "n_rows": 16, "n_features": 8,
      "source": "scm",
      "values": [[...], ...],
      "missing_mask": [[false, ...], ...],
      "query_mask": [[true, ...], ...],
      "column_types": ["numeric", ...],
      "n_classes": [null, ...],
      "query_mode": "label_column"
    }
  }]
}
```

```
curl -s http://127.0.0.1:8787/health
curl -s http://127.0.0.1:8787/v0/sources
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
  -H 'Content-Type: application/json' -d '{}'
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
  -H 'Content-Type: application/json' \
  -d '{"source": "scm", "n_units": 32, "n_features": 8, "seed": 1, "return_mechanism": true}'
curl -s -X POST http://127.0.0.1:8787/v0/episodes \
  -H 'Content-Type: application/json' \
  -d '{"source": "sklearn_iris", "n_units": 30, "n_features": 5, "seed": 0}'
```

F 机制字段对照

来源	return_mechanism 出现	不会出现
discoSCM	population + response_law	mechanism
SCM	mechanism (DAG + target_col)	population、response_law
sklearn_*	mechanism (maker / dataset)	population、response_law

形状见 data-generation.pdf 附录 H。

G 错误码

200 成功。422 字段越界 / 未知 source。501 占位未缓存。405 / 404 方法或路径不对。格子太大被 1e= 拦在 422。