

TabUF 数据生成手册

给自己看的生成手册

Heyang Gong 文献调研（协作草稿）

2026 年 8 月 15 日 草稿 v0.1

坐下来钉生成语义用的。正文只讲逻辑；公式、默认数字、*payload* 含义在附录。

怎么调服务不在这里，见 docs/api.pdf。

仓库：<https://github.com/1587causalai/tabuf-episode-api>

目录

1	先把话说清楚	3
2	我们到底要喂给网络什么	3
3	来源是通道，不是 DiscoSCM 的方言	3
4	三种世界	3
5	Compiler：出题，不改世界	4
6	已锁定，和故意以后再做	4
A	DiscoSCM：总体与 unit-specific 律	6
A.1	为什么必须先抽总体	6
A.2	Prior	6
A.3	World：特征 token 单位球 SCM，再按列类型填格	6
A.4	Compiler 在 DiscoSCM 上的默认	8
A.5	流水线	8
B	文献 SCM (TabPFN 风格 ANM)	9
C	sklearn 合成	9
C.1	sklearn_make_classification	9
C.2	sklearn_make_regression	9
C.3	sklearn_friedman1	9
C.4	sklearn_low_rank	9
D	sklearn 真实表	9

E OpenML 占位	9
F 推荐占位	10
G 各来源默认 mask	10
H 机制 payload 形状	10

1 先把话说清楚

这一节在讲什么

我们现在最缺的不是又一个网络结构，而是可训练的 **episode 从哪来**。这篇手册是写给自己的：先把生成语义钉住，再改代码。怎么调服务、字段范围，都不在这里。

工作方式不变：先改这篇文档，再改代码。绿 = 已锁定，黄 = 还没锁，灰 = 第零版故意关掉。

已锁定

第零版只生成**观测世界**。拿到的是 episode（完整表 + 两张 mask），不是 DAG，也不是潜变量 u_i 。

2 我们到底要喂给网络什么

表格基础模型的训练对象，常常被说成「一张表」。这对 TabUF 不够用。网络真正要学的，是：**已经看见一部分格子之后，去填另一部分格子**。

所以训练样本不是表，是 **episode**：一次生成 n 条，每条是一张完整表，外加 missing 与 query 两张 mask。没有单独的 y 。真值就在完整表的 query 格子上。

为什么可以是格子级，而不是永远整列标签？因为 TabUF 要能回答的，不只是「这个人缺一个标签」，还包括「这个特征在这些人身会上会是什么」。推荐场景里，这几乎是默认形态。

已锁定

训练样本是 episode：完整表 + missing + query。不是整张裸表，也不是一个 DAG。网络不准看见 u_i 。

3 来源是通道，不是 DiscoSCM 的方言

共享的只有 episode 信封：完整表 + 两张 mask。通道由生成器名字区分，默认是 discoscsm。**不要把每一条通道都读成「先抽总体再填格子」**。

名字会出现在下面的解释里——discoscsm、scm、sklearn、openml、recsys——那只是在说世界从哪来，不是在列一份调用目录。

已锁定

各来源语义独立。信封共享，生成故事不共享。

4 三种世界

行的含义看来源，不能混着讲。

DiscoSCM。 行**就是** unit，每人有潜变量 u_i 。先抽总体（位置-尺度混合： M 按 $1/M$ 落在 $1 \dots \lfloor \sqrt{n} \rfloor$ ，分量独立 Gaussian / Cauchy），再在特征 token t_j 上抽单位球 SCM（稀疏骨架 + 星枢纽 DAG、父混合后非线性 φ 、异质噪声），再用 unit-specific 线性响应律 $g_j(\langle u_i, t_j \rangle, e)$ 填格子（ K 类为线性 softmax）。这是 DiscoSCM 自己的世界 [1]。公式在附录 A。

文献 SCM / sklearn / OpenML。 行是 i.i.d. 观测（或实体行），**没有** unit token。文献里的特征 SCM（TabPFN / TabICL 风格）先抽一张特征 DAG，再抽样本，然后指定一个预测节点——我们把最后一列当作 y 。sklearn 分类/回归/真实表同样是「最后一列是标签」。低秩矩阵是例外：没有标签，按格子出题。细节在附录 B-E。

推荐。 行是 user，列是 item。未观测就是 missing；query 是已观测评分的子集。附录 F。

已锁定

只有 discoscsm 把行当成带 u_i 的 unit。scm / sklearn / OpenML 不是 DiscoSCM。recsys 也不是。

5 Compiler：出题，不改世界

无论世界从哪条通道来，Compiler 合同相同：

- values 保持完整，不因 mask 挖空。
- missing 与 query 独立抽取，**允许重合**。 $Q \cap M$ 是缺失填补， $Q \setminus M$ 是普通预测。网络可见的上下文是 $\neg M \wedge \neg Q$ 。
- 没有额外的 y 字段，也没有 y_{input} / y_{query} 。

默认比例看来源画像，不在正文里背。表在附录 G。

旧合同「 C 与 Q 把全表划成互补的两块」已经作废。现在世界可以先缺格子，再在剩下的格子上出题；两张 mask 不是划分。

已锁定

Compiler 不改世界里的数。真值用完整表在 query 处取值。 M 与 Q 可重合。训练路径禁止 u_i 进网。

6 已锁定，和故意以后再做

已锁定

- 观测 episode；不干预、不重抽反事实噪声。
- 多通道，共享信封。
- DiscoSCM：先混合总体，再特征 token 单位球 SCM（hub DAG、 φ 、异质噪声），再 unit-specific 填格。
- 其它通道按自己的世界生成，再进同一 Compiler。

- R 与 S 不许静默平均成一个头。现在只训 R 。

以后再做，现在故意不做

干预 $do(\mathbf{x})$ ；S 臂监督；把网络写进这个仓库；OpenML / 推荐缓存（接口已占位）。

还没锁，下一轮一起拍

同一个总体能否跨 episode 复用；`query_frac` 是否 curriculum；无限 DataLoader 放在这个仓库还是训练仓库。

A DiscoSCM: 总体与 unit-specific 律

这一附录是 DiscoSCM 通道的手册。其它通道不要套用这里的词。

A.1 为什么必须先抽总体

常见表格合成器骨子里是：每一行独立地再抽一遍机制。行与行可以相关，但「这一行是谁」往往没有单独的身份。

DiscoSCM 把随机性劈成两截 [1]： U 是 unit selection，一次实现 $U = u$ 就是一个个体； $\mathbf{E}$ 是这个个体身上的外生噪声，独立于 U 。结构方程是 unit-specific 的：

$$v_\ell \leftarrow f_\ell(pa_\ell, e_\ell; u). \quad (1)$$

同一个 f_ℓ ，换一个 u ，响应可以不同。 u 钉住的是个体，不是行号。

生成顺序因此钉死：先从总体 Π 实现 $\{\mathbf{u}_i\}_{i=1}^n$ ，再按 (1) 填他们在各个 feature 上的取值。不能倒过来。

一个小例子。总体里有两种人：一种对折扣敏感，一种几乎不买账。如果每一行都重新抽一套机制，网络学到的是行间噪声花样，不是「同一种人在不同列上应当怎么响应」。推荐、Uplift、个性化决策问的都是后者。没有钉住的 u ，反事实臂没有主语。

第零版不做干预，不重抽反事实噪声。只抽一次观测噪声。

A.2 Prior

总体是位置-尺度混合，不是单团 $\mathcal{N}(0, I_k)$ 。混合数

$$M \in \{1, \dots, \lfloor \sqrt{n} \rfloor\}, \quad P(M = m) \propto 1/m. \quad (2)$$

等权时每类大约至少 $\sqrt{n}$ 个人。 $P(M) \propto 1/m$ 让多数 episode 仍是 1-4 类，大表偶尔才顶到帽。权重 $\pi \sim \text{Dirichlet}(1_M)$ 。每个分量独立抽族：Gaussian 或 Cauchy。 $M = 1$ 时中心在原点、尺度 1，高斯分量就是原来的 $\mathcal{N}(0, I_k)$ ，Cauchy 分量是标准 Cauchy。 $M > 1$ 时中心放在拉开的球面上，尺度对数正态，避免簇叠成一团。Cauchy 分量的中心是位置参数，不是均值。 k 是 unit_dim，个体嵌入维数，不是网络宽度。默认 null，从先验抽样（众数约 16，支持 [2, 1024]；这组混合是手工定的）。 $\{\mathbf{u}_i\}$ 合起来就是这一集自己的总体切片。每条 episode 各自抽一回。

列数 n_features 缺省时从先验抽样（众数约 20，支持 [2, 1000]）：以 0.80 从 $\log \mathcal{N}(\log 20, 0.50^2)$ 抽取并 clip 到 [4, 64]，以 0.15 从 [20, 200] 对数均匀抽取，以 0.05 从 [200, 1000] 对数均匀抽取，最后 clip 到 [2, 1000]。显式整数则直接用（同样 clip）。unit_dim 缺省时从先验抽样（众数约 16，支持 [2, 1024]）：以 0.80 从 $\log \mathcal{N}(\log 16, 0.45^2)$ 抽取并 clip 到 [2, 64]，以 0.15 从 [32, 256] 对数均匀抽取，以 0.05 从 [256, 1024] 对数均匀抽取。这组混合是手工定的。列类型按 type_weights 多项抽样，默认权重 70:5:10:5:5 (numeric / ordinal / binary / categorical / high_cardinality)。每列以 independent_frac（默认 0.05）的概率不进特征 token DAG：无父节点，也不被当作父节点，并与 u 断开，改抽原来的类型边缘。

A.3 World: 特征 token 单位球 SCM, 再按列类型填格

格子 (i, j) 是第 i 个 unit 在第 j 个 feature 上的取值。SCM 作用在特征 token $\mathbf{t}_j \in \mathbb{R}^k$ 上，不是作用在格子值 Y 上。填格仍用原来的类型特异 g_j ：把旧的 $\mathbf{w}_j$ 换成 $\mathbf{t}_j$ ，同一个 $\mathbf{u}_i$ 贯穿这

一行（独立列除外）。 σ 是观测噪声标准差，默认 0.3。

DAG。 对非独立列：随机置换作为拓扑序。先抽稀疏骨架：典型父节点上限 `typical_cap = 6` (`max_parents=null`)，入度 $k \sim \text{Poisson}(\lambda = 2.2)$ 再 clip 到上限，从拓扑前驱按优先连接 $P(p) \propto \text{outdeg}[p] + 1$ 抽 k 个父节点。这是**大概率**的常见图。另以概率 0.15（或请求 `graph_family=star`）叠 1–2 个显式星：抽 $\text{frac} \sim \text{Unif}[0.45, 0.85]$ ，前三分之一一个 out-hub、后三分之一一个 in-hub，使极少数节点有很多父或很多子。`graph_family=sparse` 强制不叠星。请求里显式给出 `max_parents` 时，该整数是所有节点的硬上限，不叠星。`dag_edge_p` 是遗留字段：仍接受、仍写入 `response_law`，但不再按 $\text{Bernoulli}(p)$ 连边。独立列不出现在这张 DAG 里。

Token SCM。 β 是父节点混合权重（L1 归一， $\sum |\beta| = 1$ ）；效应强度是遗传力 α （默认 0.75）。相对 $|\beta|$ 先按 NOTEARS/LiNGAM 惯例从 $\text{Unif}[\beta_{\min}, \beta_{\max}]$ （默认 $[0.5, 2]$ ）抽取、符号独立取 ± 1 ，再 L1 归一；单父时 $\beta = \pm 1$ 。 $\text{Unif}[0.5, 2]$ 只决定多父时的相对比例，normalize 之前。不要再用 $\mathcal{N}(0, 0.4^2)$ 。按拓扑序在单位球上生成 $\mathbf{t}_j$ 。根节点（无父） $\mathbf{t}_j = \text{normalize}(\eta_j)$ ， $\varphi_j = \text{identity}$ 。有父时先线性混合再过非线性

$$\mathbf{s}_j^{\text{raw}} = \sum_{p \in \text{pa}(j)} \beta_{jp} \mathbf{t}_p, \quad \mathbf{s}_j = \text{normalize}(\varphi_j(\mathbf{s}_j^{\text{raw}})), \quad (3)$$

φ_j 以 0.50/0.20/0.20/0.10 抽 $\{\text{identity}, \tanh, \text{leaky_relu}, \sin\}$ （leaky ReLU 负半轴系数 0.2）。再抽与 $\mathbf{s}_j$ 正交的创新：先从该列噪声族抽 η_{raw} ， $\eta_j = \text{normalize}(\eta_{\text{raw}} - \langle \eta_{\text{raw}}, \mathbf{s}_j \rangle \mathbf{s}_j)$ 。遗传力 $\alpha = \text{token_heritability}$ 截到 (0.05, 0.95)，默认 0.75：

$$\mathbf{t}_j = \text{normalize}(\alpha \mathbf{s}_j + \sqrt{1 - \alpha^2} \eta_j). \quad (4)$$

因此 $\varphi = \text{identity}$ 时 $\langle \mathbf{t}_j, \mathbf{s}_j \rangle \approx \alpha$ ；其它 φ 会把子–父余弦从 α 上挪开一点。

噪声族。 每列（含根节点与独立列）以 0.50/0.30/0.20 抽 $\{\text{gaussian}, t, \text{Cauchy}\}$ ； t 的自由度在 $\{3, 4, 5, 6\}$ 上均匀。该族用于：根 token、正交创新 η_{raw} 、以及 numeric / binary / ordinal 的观测噪声 e_{ij} （乘 σ ，student- t / Cauchy 不再标准化到方差 1）。独立 numeric 为 $\mu + \sigma_j \cdot \text{draw}$ 。类别列用线性 softmax（见下），观测噪声 e 不进类别 logits。

数值。 $Y_{ij} = \text{scale}_j \langle \mathbf{u}_i, \mathbf{t}_j \rangle + \text{shift}_j + e_{ij}$ 。独立列则是列级高斯边缘。

二值。 潜变量阈值： $\mathbf{1}\{\langle \mathbf{u}_i, \mathbf{t}_j \rangle + e_{ij} > 0\}$ 。独立列是 Bernoulli。

有序。 ordered probit：在 $\langle \mathbf{u}_i, \mathbf{t}_j \rangle + e_{ij}$ 上切 $K_j - 1$ 个阈值， $K_j \in \{3, \dots, 8\}$ 。

多值 / 超多值。 列 token 仍是 $\mathbf{t}_j$ 。类嵌入取

$$\mathbf{C}_c = a_c \mathbf{t}_j + 0.25 \mathbf{r}_c, \quad \mathbf{r}_c \perp \mathbf{t}_j, \quad (5)$$

其中 r_c 落在 t_j 的正交补上（因此共享方向钉在 t_j ；超多值时 a_c 尺度更散）。响应在 u 上是线性的：

$$\text{logits}_i = \mathbf{u}_i C^\top, \quad p_i = \text{softmax}(\text{logits}_i), \quad Y_{ij} \sim \text{Categorical}(p_i). \quad (6)$$

φ 只作用在 token SEM 的 $\mathbf{s}^{\text{raw}}$ 上，不作用在 Y 。独立列是 Dirichlet-多项边缘。

离散格点是 $\{0, \dots, K_j - 1\}$ 的整数。数值格是 float。世界填满之后，掩码不许回头改 Y_{ij} 。

A.4 Compiler 在 DiscoSCM 上的默认

格子级。默认 $P(M) = 0.05$ 、 $P(Q) = 0.15$ ，独立抽取，并集不必是 20%。query_mode=cells。uses_unit_token=true。n_units 默认 1000（API 上限 4096）。n_features 默认 null（从先验抽样，众数约 20，支持 $[2, 1000]$ ）。unit_dim 默认 null（从先验抽样，众数约 16，支持 $[2, 1024]$ ）。

return_mechanism 或 debug 时带 population（含混合总体 mixture / assignment / representations）和 response_law（DAG 的 parents / betas、dag_edge_p（遗留）/ max_parents / typical_max_parents / max_in_degree / hubs / out_hubs / in_hubs / activations / noise_families / n_features_sampled / token_heritability / beta_min / beta_max、特征 token t_j 、以及逐列 g_j 的参数，含 noise_family）。默认响应仍省略这些块。它们描述表从哪来，不是给网络的输入。形状见附录 H。

A.5 流水线

空请求按图 1 走。默认挂在对应步骤上。

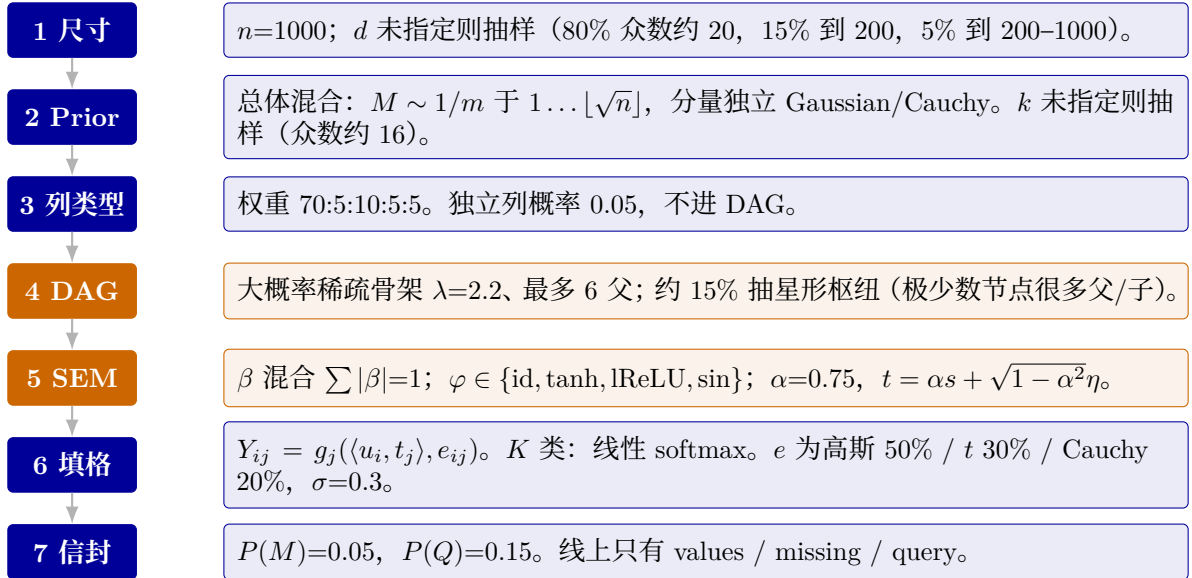


图 1: DiscoSCM 观测 episode 生成流水线。因果在特征 token 上，不在格子值上。

Prior $\rightarrow$ World $\rightarrow$ Compiler。网络不进生成器。真目标表上从第一天就冻 θ ，合成引擎只负责预训练 episode。

以后会变复杂的方向（只指路）：World 级缺失先于出题；非线性 f_j 仍由同一个 u 贯穿一行；干预 episode 才给 S 臂真实监督； n, d curriculum。每加一层先改这一附录，再改代码。

B 文献 SCM (TabPFN 风格 ANM)

不是 DiscoSCM。没有 unit token。行是 i.i.d. 观测样本。

在 d 个特征上抽一张随机 DAG，按拓扑序生成加性噪声 SCM：根节点是噪声；否则父节点的线性组合或 $\tanh$ ，再加 $\mathcal{N}(0, \sigma^2)$ 。最后一列指定为预测目标 y （文献惯例：先抽 SCM，再挑一个节点来预测）。

这里的行数旋钮表示 $n_{\text{samples}} \circ \text{unit_dim} / \text{type_weights} / \text{independent_frac} / \text{population}$ 不适用，响应里不会出现。

默认 `query_mode=label_column,missing_frac=0`。机制在字段 `mechanism`，键为 `framework`、`edges`、`node_fn`、`target_col`。`target_col=d-1`。这是特征 DAG，不是个体响应律。不要读 `population / response_law`。

C sklearn 合成

行是 i.i.d. 样本。没有 unit token。没有 population。机制在 `mechanism`，带 `maker`。别名仍可用：省略子名则随机抽一个 `maker`，并套用该 `maker` 的画像。

C.1 sklearn_make_classification

最后一列二值 y 。默认 `label_column`，`missing 0`。

C.2 sklearn_make_regression

最后一列连续 y 。默认 `label_column`，`missing 0`。

C.3 sklearn_friedman1

Friedman #1。最后一列连续 y 。默认 `label_column`，`missing 0`。

C.4 sklearn_low_rank

低秩矩阵。没有标签列。默认 `cells`，`missing 0.05 / query 0.15`，按矩阵补全出题。

D sklearn 真实表

行是实体行 (`entity_row`)，不是 unit。对原表按请求的行数、列数子采样，保留最后一列。默认 `label_column`，`missing 0`。

`sklearn_iris`、`sklearn_wine`、`sklearn_breast_cancer`：最后一列类别。`sklearn_diabetes`：最后一列连续靶。别名套用被抽中的真实表。

E OpenML 占位

监督表。行是 `entity_row`。默认 `label_column`，`missing 0`。缓存接上之前这条通道还不能出表。不要用 DiscoSCM 的词描述它。

F 推荐占位

User×Item 矩阵。行含义是 user。未观测格是 missing；query 是已观测评分的子集（模式 observed_cells）。缓存接上之前这条通道还不能出表。

G 各来源默认 mask

通道	行含义	query_mode	missing	query
discoscm	unit	cells	0.05	0.15
scm	iid_sample	label_column	0	(整列 y)
sklearn 分类/回归/Friedman	iid_sample	label_column	0	(整列 y)
sklearn_low_rank	iid_sample	cells	0.05	0.15
sklearn 真实表	entity_row	label_column	0	(整列标签)
openml	entity_row	label_column	0	(整列标签)
recsys	user	observed_cells	未观测	已观测的 0.15

请求里写了 missing / query / query_mode 则覆盖画像。行数旋钮一律控制行数；只有 discoscm 把这些行当成 unit。

H 机制 payload 形状

线上字段名以 docs/api.pdf 为准。这里只讲含义：这些块描述表从哪来，不是网络输入。

discoscm 在 return_mechanism 或 debug 时给两块：population 含 id、n_units、unit_dim、prior(location_scale_mixture)、mixture(M、weights、逐分量 family/location/scale)、assignment、representations(行 i 是 u_i)；response_law 含 form(feature_token_linear_scm)、type_weights、column_independent_prob、dag_edge_p(遗留)、max_parents、typical_max_parents、max_in_degree、token_heritability、beta_min、beta_max、n_features_sampled、parents、betas、tokens(独立列为 null)、activations、noise_families、hubs / out_hubs / in_hubs、以及逐列 columns(含 noise_family / noise_df)。默认响应省略这些块。没有 mechanism 字段。

scm 给 mechanism: framework=ANM-SCM、edges、node_fn、target_col。没有 population / response_law。

sklearn 给 mechanism: framework 加 maker 或 dataset。没有 population / response_law。训练 DataLoader 不准吃这些块。

参考文献

[1] Heyang Gong, Chaochao Lu, Yu Zhang. Distribution-consistency Structural Causal Models. 2024. 本地指南: discoscm/latex/main-guide.tex.

[2] Judea Pearl. *Causality*. Cambridge University Press, 2nd edition, 2009.

[3] Paul W. Holland. Statistics and causal inference. *JASA*, 1986.